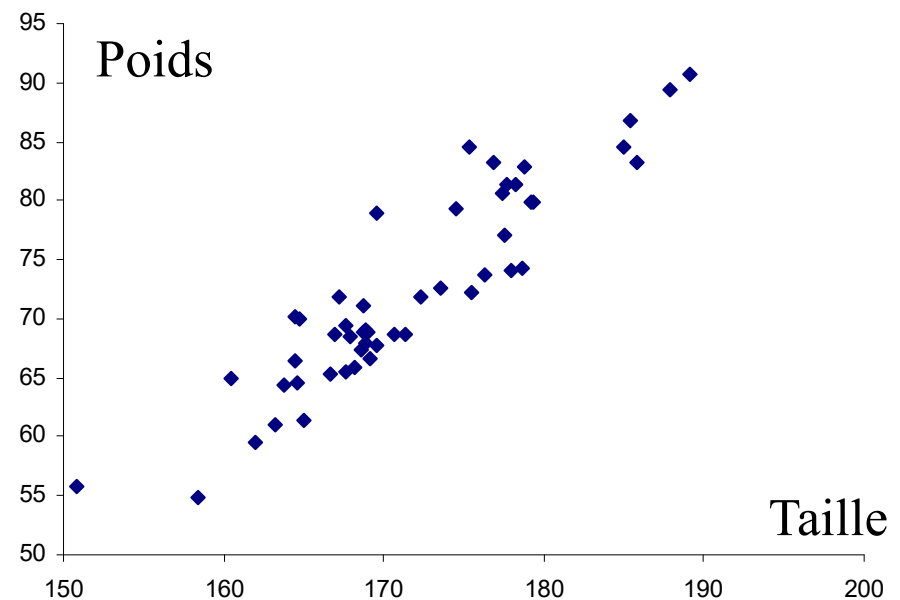




ETUDE DE 2 VARIABLES QUANTITATIVES

(1) MESURE DE LA LIAISON ENTRE 2 VARIABLES QUANTITATIVES


Nom	Taille x_i (cm)	Poids y_i (kg)
Pierre	175	73
Arantxa	168	56
.....
Martin	185	87



La connaissance de la taille x apporte une certaine information sur le poids y


Il existe une **relation de dépendance** entre x et y

(2) MESURE DE LA LIAISON ENTRE 2 VARIABLES QUANTITATIVES



La connaissance de x n'apporte aucune certaine information sur y

x et y sont **indépendantes**



La connaissance de x permet de connaître exactement la valeur de y

Il existe une **relation fonctionnelle** entre x et y

(3) MESURE DE LA LIAISON ENTRE 2 VARIABLES QUANTITATIVES

Covariance :
$$\text{Cov}(x,y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Propriétés :

$$\text{Cov}(x,y) > 0 \Leftrightarrow x \text{ et } y \text{ varient dans le même sens}$$

$$\text{Cov}(x,y) < 0 \Leftrightarrow x \text{ et } y \text{ varient en sens contraire}$$

$$\text{Cov}(x,y) = \text{Cov}(y,x)$$

$$\text{Cov}(x,x) = V(x)$$

$$\text{Cov}(a x + b y, z) = a \text{Cov}(x,z) + b \text{Cov}(y,z)$$

(4) MESURE DE LA LIAISON ENTRE 2 VARIABLES QUANTITATIVES

Corrélation linéaire: $\rho = \frac{\text{cov}(x,y)}{\sigma(x) \sigma(y)}$

Propriétés :

$$-1 \leq \rho \leq 1$$

$$y = a x + b \Leftrightarrow \begin{cases} \rho = 1 & \text{si } a > 0 \\ \rho = -1 & \text{si } a < 0 \end{cases}$$

$$|\rho| = 1 \Leftrightarrow \text{Il existe une relation fonctionnelle entre } x \text{ et } y$$

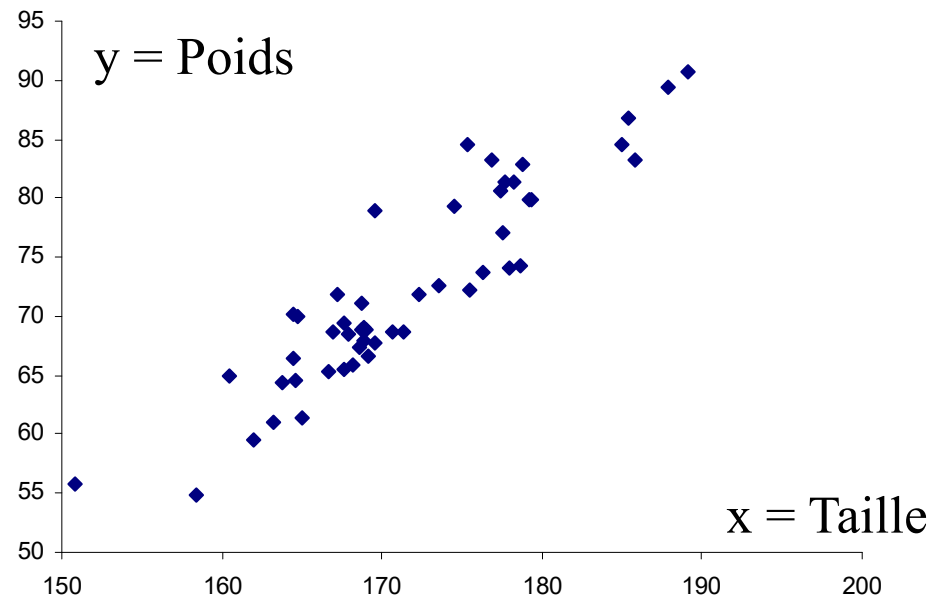
$$\rho = 0 \Leftrightarrow x \text{ et } y \text{ sont indépendantes}$$

$$0 < |\rho| < 1 \Leftrightarrow \text{Il existe une dépendance linéaire d'autant plus forte que } |\rho| \text{ est grand}$$



Ne pas confondre causalité et corrélation

(1) AJUSTEMENT LINEAIRE




Est-il possible de trouver une fonction numérique f telle que $y = f(x)$?

Si une telle fonction existe, on dit que f est un **modèle** du phénomène étudié.

x est la variable explicative.

y est la variable expliquée.

(2) AJUSTEMENT LINEAIRE



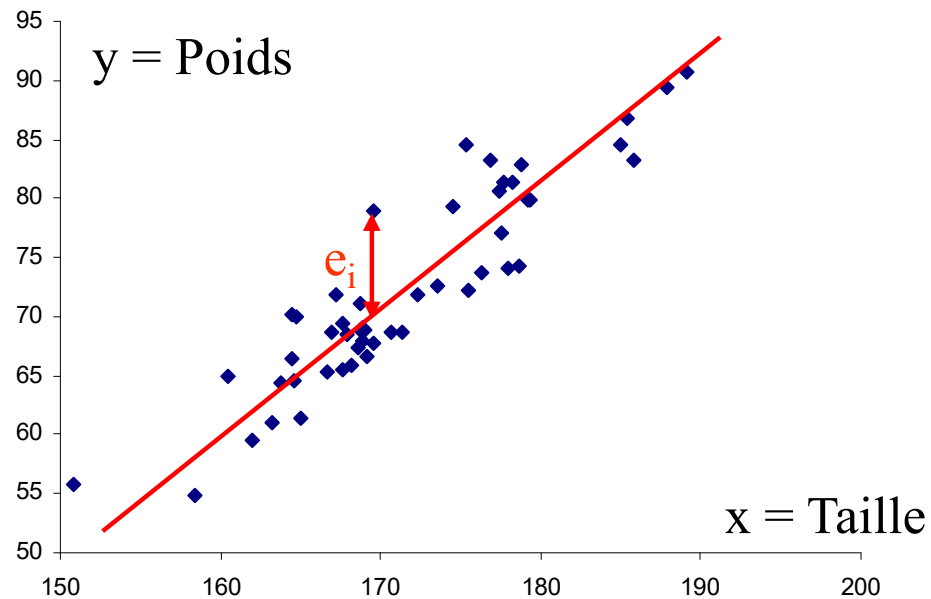
On désire trouver la droite qui passe « **au mieux** » à l'intérieur du nuage de points

(3) AJUSTEMENT LINEAIRE


« au mieux »

Minimiser $S = \sum_{i=1}^n e_i^2$

Minimiser $S' = \sum_{i=1}^n e_i'^2$



Droite de régression de y en x

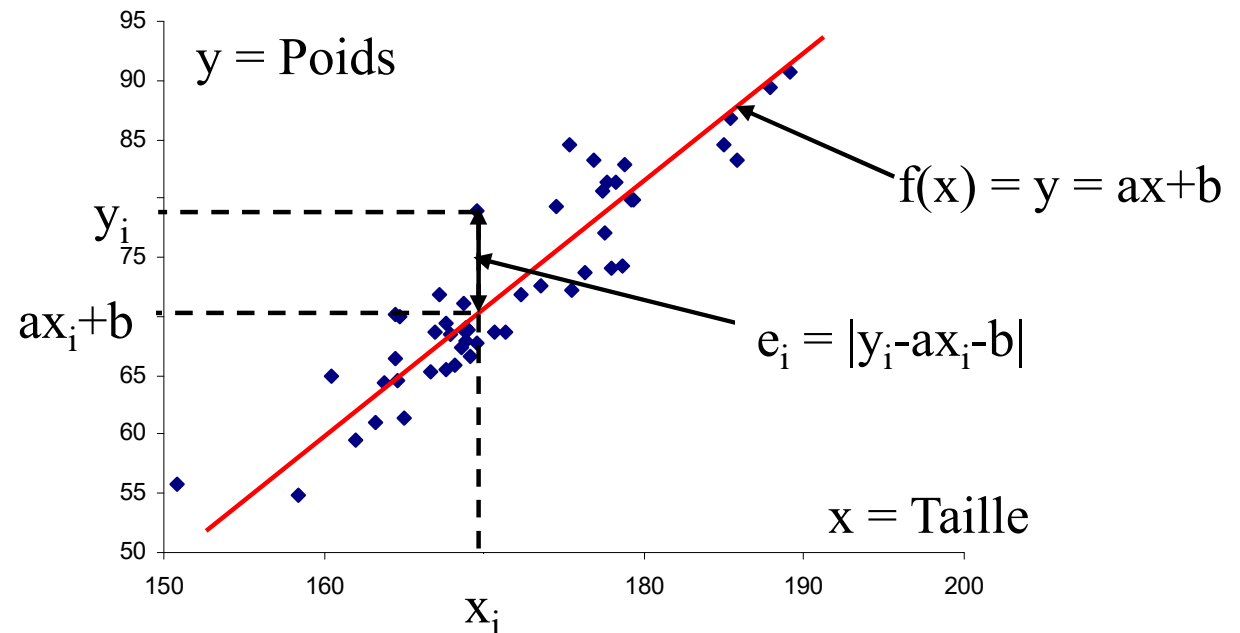


Droite de régression de x en y

(4) AJUSTEMENT LINEAIRE

REGRESSION LINEAIRE DE Y EN X

Droite de régression
linéaire de y en x
 $y = f(x) = ax + b$



La droite de régression linéaire de y en x, notée $D_{y/x}$, minimise $S = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - ax_i - b)^2$


$$a = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{V(x)}$$

$$b = \bar{y} - a\bar{x}$$

$D_{y/x}$ passe par le point moyen (\bar{x}, \bar{y})

(5) AJUSTEMENT LINEAIRE REGRESSION LINEAIRE DE Y EN X

Droite de régression
linéaire de y en x
 $y = f(x) = ax + b$



$y = a x + b$ définit un modèle affine


$\hat{y}_i = a x_i + b$ = valeur de y_i prévue par le modèle

$r_i = y_i - \hat{y}_i$ = résidu de la ième observation

$e_i = |r_i| = |y_i - a x_i - b|$ = erreur due au modèle

(6) AJUSTEMENT LINEAIRE REGRESSION LINEAIRE DE X EN Y

Droite de régression
linéaire de x en y
 $x = f(y) = a'y + b'$



La droite de régression linéaire de x en y, notée $D_{x/y}$, minimise $S' = \sum_{i=1}^n e_i'^2 = \sum_{i=1}^n (x_i - a'y_i - b')^2$

$$a' = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\text{Cov}(x, y)}{V(y)}$$

$$b' = \bar{x} - a' \bar{y}$$

$D_{x/y}$ passe par le point moyen (\bar{x}, \bar{y})

LIENS ENTRE CORRELATION ET DROITES DE REGRESSION


$$D_{y/x} : y = ax + b \quad a = \frac{\text{Cov}(x,y)}{V(x)} \quad b = \bar{y} - a\bar{x}$$

$$\rho^2 = a a'$$

$$\rho = a \frac{\sigma(x)}{\sigma(y)} = a' \frac{\sigma(y)}{\sigma(x)}$$


$$D_{x/y} : x = a'y + b' \quad a' = \frac{\text{Cov}(x,y)}{V(y)} \quad b' = \bar{x} - a'\bar{y}$$

$$\Leftrightarrow y = \frac{1}{a'}x - \frac{b'}{a'}$$




$$\rho^2 = a a' = 0$$

Indépendance linéaire



$$0 < \rho^2 = a a' < 1$$

Le degré de dépendance linéaire se mesure à la proximité des droites de régression


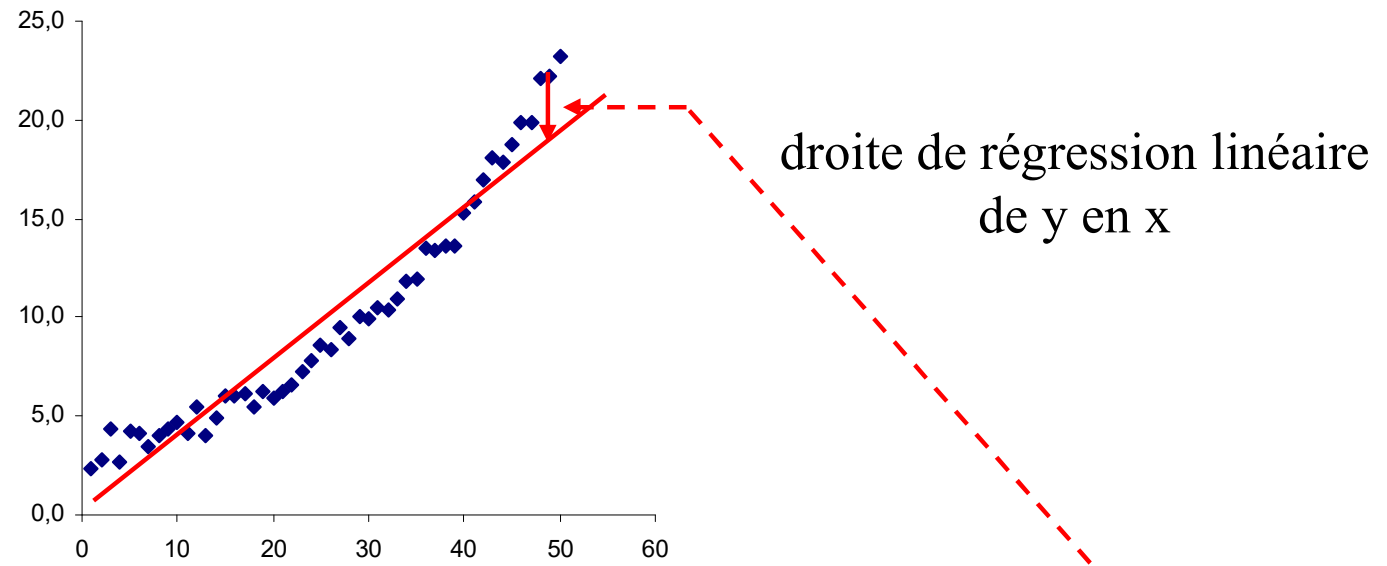


$$\rho^2 = a a' = 1$$

Liaison fonctionnelle linéaire

(1) AJUSTEMENT A UNE FONCTION EXPONENTIELLE


x_i	y_i
2,8	0,8
4,3	1,2
2,7	1,5
4,2	1,9
4,1	2,3
....
4,0	3,1



Analyse des résidus

Les résidus devraient se répartir au hasard autour de l'axe des abscisses:
le modèle affine ne convient pas

(2) AJUSTEMENT A UNE FONCTION EXPONENTIELLE



Modèle exponentiel

$$y = e^x \quad \text{exponentielle de base } e$$

$$y = a^x \quad \text{exponentielle de base } a$$

$$y = b a^x \quad \text{Forme exponentielle générale}$$

Changement de variable

$$\ln y = \ln b + x \ln a$$

$$Y = A X + B \quad \text{avec} \quad Y = \ln y$$

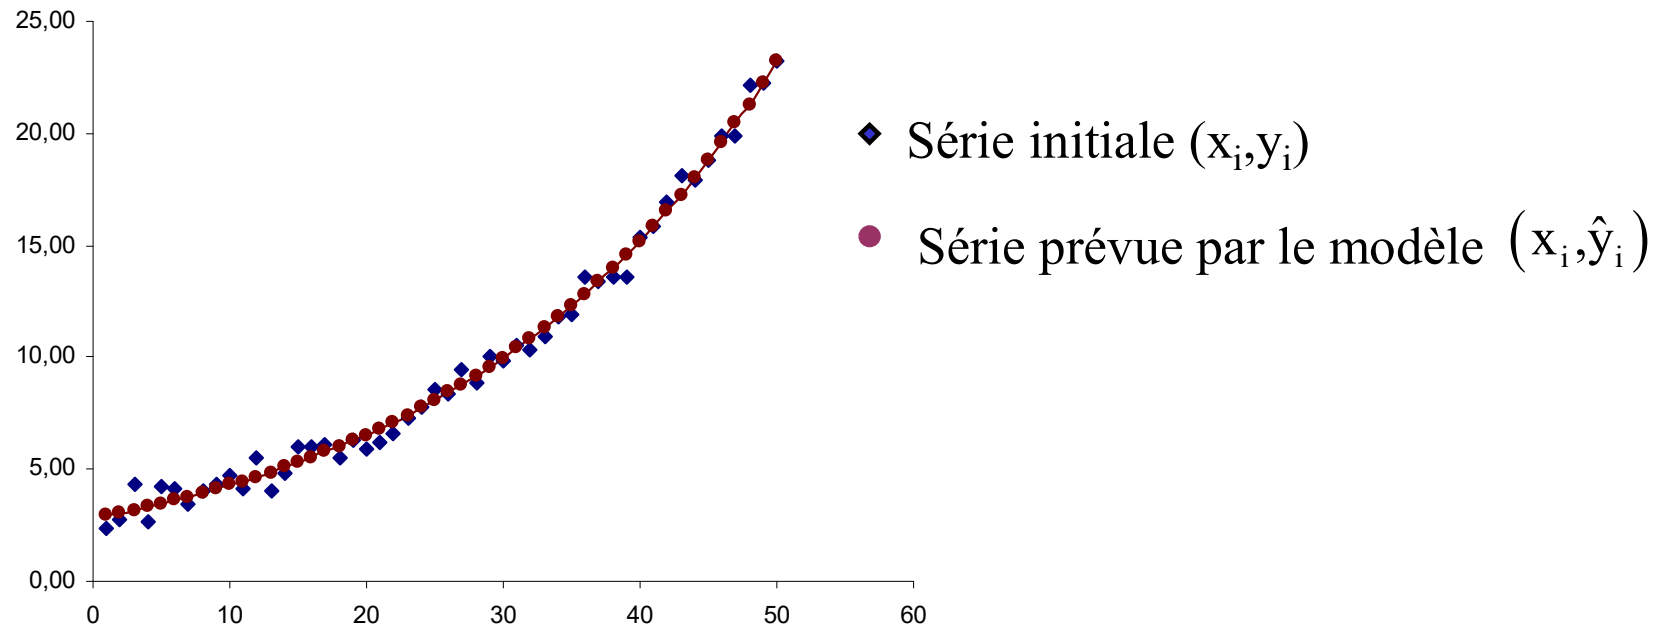
$$X = x$$

$$A = \ln a$$


$$B = \ln b$$

L'ajustement affine de Y en fonction de X donne A et B,
d'où $a = e^A$, $b = e^B$, et le modèle $y = b a^x$

(3) AJUSTEMENT A UNE FONCTION EXPONENTIELLE




Analyse des résidus




Le modèle exponentiel est mieux adapté que le modèle affine

(1) AJUSTEMENT A UNE FONCTION PUISSANCE




Droite de régression linéaire de y en x



Analyse des résidus

Le modèle affine ne
convient pas

(2) AJUSTEMENT A UNE FONCTION PUISSANCE



Modèle puissance

$$y = b x^a$$

Changement de variable

$$\ln y = \ln b + a \ln x$$

$$Y = A X + B$$

avec

$$Y = \ln y$$


$$X = \ln x$$

$$A = a$$

$$B = \ln b$$

L'ajustement affine de Y en fonction de X donne A et B,
d'où $a = A$, $b = e^B$, et le modèle $y = b x^a$


(3) AJUSTEMENT A UNE FONCTION PUISSANCE



◆ Série initiale (x_i, y_i)

● Série prévue par le modèle (x_i, \hat{y}_i)

Analyse des résidus



Le modèle puissance est mieux adapté que le modèle affine

QUALITE D'UN AJUSTEMENT

On montre que
$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$

$$SCT = SCM + SCR \Leftrightarrow 1 = \frac{SCM}{SCT} + \frac{SCR}{SCT}$$

Somme des carrés des écarts à la moyenne = Somme des carrés des écarts du modèle + Somme des carrés des résidus

L'ajustement est d'autant meilleur que SCR est proche de 0, c.à.d. que SCR/SCT est proche de 0 ou SCM/SCT est proche de 1.

$$R = \frac{SCM}{SCT} = \text{Coefficient de détermination} = \rho^2 = (\text{coef. de corrélation})^2$$

= proportion de la variation totale due à l'ajustement

$$0 \leq R \leq 1$$